

第三讲

考虑无约束优化问题

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) \quad (1)$$

此处假设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微.

采用如下迭代法求解该优化问题, 相应的迭代格式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - h_k \mathbf{d}_k,$$

其中 $\{h_k\}$ 为预设步长, $\mathbf{d}_k$ 为移动方向.

1 最优下降方向及步长选择

由 f 可微知 (Proposition 1.0.14, Lecture 1)

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - h_k \mathbf{d}_k) = f(\mathbf{x}_k) - h_k \nabla f(\mathbf{x}_k)^T \mathbf{d}_k + o(h_k \|\mathbf{d}_k\|).$$

给定步长 h_k , 设 $\mathbf{d}_k$ 为单位向量, 即 $\|\mathbf{d}_k\| = 1$, 最优方向应该使得 $f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$ 尽可能地大, 即使得每一次迭代函数值以最快的速度下降, 此时应使得

$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_k$$

取最大值.

由 Cauchy-Schwartz 不等式

$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_k \leq \|\nabla f(\mathbf{x}_k)\| \cdot \|\mathbf{d}_k\| = \|\nabla f(\mathbf{x}_k)\|.$$

当 $\nabla f(\mathbf{x}_k) = 0$ 或 $\mathbf{d}_k = \frac{\nabla f(\mathbf{x}_k)}{\|\nabla f(\mathbf{x}_k)\|}$ 时等号成立, 即最优方向 $\mathbf{d}_k$ 与 $\nabla f(\mathbf{x}_k)$ 同向. 相应的迭代格式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - h_k \nabla f(\mathbf{x}_k),$$

称为[梯度下降法](#).

若注意到 $\nabla f(\mathbf{x}_k) \neq 0$,

$$\lim_{t \rightarrow 0^+} \frac{f(\mathbf{x}_k - t \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)}{t} = f'(\mathbf{x}_k; -\nabla f(\mathbf{x}_k)) = -\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k) < 0$$

故存在步长 t_k , 使得 $f(\mathbf{x}_k - t_k \nabla f(\mathbf{x}_k)) < f(\mathbf{x}_k)$, 函数值随着迭代进行单调不增.

迭代步长常用的三种选择包括,

- 常数步长 $h_k = h > 0$
- 精确线搜索 (exact line search)

$$h_k = \arg \min_{h>0} f(\mathbf{x}_k - h \nabla f(\mathbf{x}_k)).$$

- 回溯法 (backtracking) 设有参数 $s > 0, \alpha \in (0, 1), \beta \in (0, 1)$. 取 $h_k = s$, 若

$$f(\mathbf{x}_k) - f(\mathbf{x}_k - h_k \nabla f(\mathbf{x}_k)) < \alpha h_k \|\nabla f(\mathbf{x}_k)\|^2$$

取 $h_k = \beta h_k$. 即取步长 $h_k = \beta^{i_k} s$, 使之满足

$$f(\mathbf{x}_k) - f(\mathbf{x}_k - \beta^{i_k} s \nabla f(\mathbf{x}_k)) \geq \alpha \beta^{i_k} s \|\nabla f(\mathbf{x}_k)\|^2,$$

i_k 为步长首次满足上述不等式的在第 k 次迭代中回溯法执行的次数. 回溯法能够在有限步内停止.(原因是什么?)

2 L -smooth 条件下的收敛性分析

假设目标函数 f 满足一阶 Lipschitz 连续性质, 即

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|$$

由 Theorem 2.0.8, Lecture 2, 立即可以得到以下充分下降引理

引理 2.1: 充分下降引理

设 f 为 L -smooth, 则对任意 $\mathbf{x} \in \mathbb{R}^d$ 及 $h > 0$, 有

$$f(\mathbf{x}) - f(\mathbf{x} - h \nabla f(\mathbf{x})) \geq h(1 - \frac{Lh}{2}) \|\nabla f(\mathbf{x})\|^2.$$

充分下降引理说明, 若要获得足够大的目标函数下降量, 应关于步长 h 最大化 $h(1 - \frac{Lh}{2})$, 此时 $h = \frac{1}{L}$, 相应地, 在梯度下降法中有

$$f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2.$$

引理 2.2

设 f 为 L -smooth, $\{\mathbf{x}_k\}$ 为梯度下降法产生的迭代序列, 步长策略取常数步长 $h \in (0, \frac{2}{L})$, 或精确线搜索, 或以 (s, α, β) 为参数的回溯法, 均有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

其中

$$M = \begin{cases} h(1 - \frac{Lh}{2}), & \text{常数步长;} \\ \frac{1}{2L}, & \text{精确线搜索;} \\ \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\}, & \text{回溯法.} \end{cases}$$

证明. 情形 1: 常数步长 $h \in (0, \frac{2}{L})$ 充分下降引理的直接结论.

情形 2: 精确线搜索 设 $\bar{h} = \arg \min_{h>0} f(\mathbf{x}_k - h\nabla f(\mathbf{x}_k))$, $\mathbf{x}_{k+1} = \mathbf{x}_k - \bar{h}\nabla f(\mathbf{x}_k)$.

由 $\bar{h}$ 的最优性, 有

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - \bar{h}\nabla f(\mathbf{x}_k)) \leq f(\mathbf{x}_k - \frac{1}{L}\nabla f(\mathbf{x}_k)),$$

故

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq f(\mathbf{x}_k) - f(\mathbf{x}_k - \frac{1}{L}\nabla f(\mathbf{x}_k)) \geq \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2.$$

情形 3: 回溯法 若 $s(1 - \frac{Ls}{2}) \geq \alpha s$, 由充分下降引理, 此时回溯法步长 $h_k = s$.

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha s \|\nabla f(\mathbf{x}_k)\|^2.$$

否则, 由回溯法的执行过程知

$$\beta^{i_k-1} s(1 - \frac{L\beta^{i_k-1}s}{2}) \leq f(\mathbf{x}_k) - f(\mathbf{x}_k - \beta^{i_k-1}s\nabla f(\mathbf{x}_k)) < \alpha \beta^{i_k-1} \|\nabla f(\mathbf{x}_k)\|^2$$

解得 $\beta^{i_k}s > \frac{2(1-\alpha)\beta}{L}$,

故 $h_k \geq \min\{s, \frac{2(1-\alpha)\beta}{L}\}$, 又因为回溯法步长满足

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha h_k \|\nabla f(\mathbf{x}_k)\|^2 \geq \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\} \|\nabla f(\mathbf{x}_k)\|^2.$$

□

定理 2.1

设 f 为 L -smooth, $\{\mathbf{x}_k\}$ 为梯度下降法产生的迭代序列, $\mathbf{x}^*$ 为无约束优化问题的全局最优解, 则

$$\min_{k=0,\dots,K} \|\nabla f(\mathbf{x}_k)\| \leq \sqrt{\frac{f(\mathbf{x}_0) - f(\mathbf{x}^*)}{M(K+1)}},$$

其中

$$M = \begin{cases} h(1 - \frac{Lh}{2}), & \text{常数步长;} \\ \frac{1}{2L}, & \text{精确线搜索;} \\ \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\}, & \text{回溯法.} \end{cases}$$

证明. 由引理 2.2 有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

记 $\Delta_k = f(\mathbf{x}_k) - f(\mathbf{x}^*)$, 则

$$M \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_k - \Delta_{k+1}, \quad k = 0, 1, \dots, K$$

对此 $K+1$ 项求和, 可得

$$(K+1)M \left(\min_{k=0,\dots,K} \|\nabla f(\mathbf{x}_k)\| \right)^2 \leq M \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_0 - \Delta_{K+1} \leq \Delta_0 = f(\mathbf{x}_0) - f(\mathbf{x}^*).$$

整理得到

$$\min_{k=0,\dots,K} \|\nabla f(\mathbf{x}_k)\| \leq \sqrt{\frac{f(\mathbf{x}_0) - f(\mathbf{x}^*)}{M(K+1)}}.$$

□