

最优化方法 第四讲

Weiwen Wang(王伟文)

暨南大学

2025 年 4 月 2 日

目录

- 1 无约束优化
- 2 最优下降方向及步长选择
- 3 充分下降引理
 - 充分下降引理的最优步长
 - 不同步长策略的下降性质
- 4 L -smooth 函数收敛性
 - L -smooth 函数收敛性证明
- 5 凸函数
 - 凸函数的收敛性
- 6 L -smooth 凸函数
 - L -smooth 凸函数收敛性
- 7 L -smooth 及 μ -强凸函数
 - L -smooth 及 μ -强凸函数的收敛性

无约束优化

考虑无约束优化问题

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) \quad (1)$$

此处假设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微.

采用如下迭代法求解该优化问题, 相应的迭代格式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - h_k \mathbf{d}_k,$$

其中 $\{h_k\}$ 为预设步长, $\mathbf{d}_k$ 为移动方向.

由 f 可微知 (Proposition 1.0.14, Lecture 1)

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - h_k \mathbf{d}_k) = f(\mathbf{x}_k) - h_k \nabla f(\mathbf{x}_k)^T \mathbf{d}_k + o(h_k \|\mathbf{d}_k\|).$$

由 f 可微知 (Proposition 1.0.14, Lecture 1)

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - h_k \mathbf{d}_k) = f(\mathbf{x}_k) - h_k \nabla f(\mathbf{x}_k)^T \mathbf{d}_k + o(h_k \|\mathbf{d}_k\|).$$

给定步长 h_k , 设 $\mathbf{d}_k$ 为单位向量, 即 $\|\mathbf{d}_k\| = 1$, 最优方向应该使得 $f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$ 尽可能地大, 即使得每一次迭代函数值以最快的速度下降, 此时应使得

$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_k$$

取最大值.

由 Cauchy-Schwartz 不等式

$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_k \leq \|\nabla f(\mathbf{x}_k)\| \cdot \|\mathbf{d}_k\| = \|\nabla f(\mathbf{x}_k)\|.$$

由 Cauchy-Schwartz 不等式

$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_k \leq \|\nabla f(\mathbf{x}_k)\| \cdot \|\mathbf{d}_k\| = \|\nabla f(\mathbf{x}_k)\|.$$

当 $\nabla f(\mathbf{x}_k) = 0$ 或 $\mathbf{d}_k = \frac{\nabla f(\mathbf{x}_k)}{\|\nabla f(\mathbf{x}_k)\|}$ 时等号成立, 即最优方向 $\mathbf{d}_k$ 与 $\nabla f(\mathbf{x}_k)$ 同向. 相应的迭代格式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - h_k \nabla f(\mathbf{x}_k),$$

称为**梯度下降法**.

若注意到 $\nabla f(\mathbf{x}_k) \neq 0$,

$$\lim_{t \rightarrow 0^+} \frac{f(\mathbf{x}_k - t \nabla f(\mathbf{x}_k)) - f(\mathbf{x}_k)}{t} = f'(\mathbf{x}_k; -\nabla f(\mathbf{x}_k)) = -\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k) < 0$$

故存在步长 t_k , 使得 $f(\mathbf{x}_k - t_k \nabla f(\mathbf{x}_k)) < f(\mathbf{x}_k)$, 函数值随着迭代进行单调不增.

步长策略

迭代步长常用的三种选择包括,

- 常数步长 $h_k = h > 0$
- 精确线搜索 (exact line search)

$$h_k = \arg \min_{h>0} f(\mathbf{x}_k - h \nabla f(\mathbf{x}_k)).$$

- 回溯法 (backtracking) 设有参数 $s > 0$, $\alpha \in (0, 1)$, $\beta \in (0, 1)$. 取 $h_k = s$. 若

$$f(\mathbf{x}_k) - f(\mathbf{x}_k - h_k \nabla f(\mathbf{x}_k)) < \alpha h_k \|\nabla f(\mathbf{x}_k)\|^2$$

取 $h_k = \beta h_k$. 即取步长 $h_k = \beta^{i_k} s$, 使之满足

$$f(\mathbf{x}_k) - f(\mathbf{x}_k - \beta^{i_k} s \nabla f(\mathbf{x}_k)) \geq \alpha \beta^{i_k} s \|\nabla f(\mathbf{x}_k)\|^2,$$

i_k 为步长首次 满足上述不等式的在第 k 次迭代中回溯法执行的次数. 回溯法能够在有限步内停止.(**原因是什么?**)

充分下降引理

假设目标函数 f 满足一阶 Lipschitz 连续性质, 即

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$$

由 Theorem 2.0.8, Lecture 2, 立即可以得到以下充分下降引理

引理 1 (充分下降引理)

设 f 为 L -smooth, 则对任意 $\mathbf{x} \in \mathbb{R}^d$ 及 $h > 0$, 有

$$f(\mathbf{x}) - f(\mathbf{x} - h\nabla f(\mathbf{x})) \geq h(1 - \frac{Lh}{2})\|\nabla f(\mathbf{x})\|^2.$$

充分下降引理的最优步长

充分下降引理说明, 若要获得足够大的目标函数下降量, 应关于步长 h 最大化 $h(1 - \frac{Lh}{2})$, 此时 $h = \frac{1}{L}$, 相应地, 在梯度下降法中有

$$f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2.$$

不同步长策略的下降性质

引理 2

设 f 为 L -smooth, $\{\mathbf{x}_k\}$ 为梯度下降法产生的迭代序列, 步长策略取常数步长 $h \in (0, \frac{2}{L})$, 或精确线搜索, 或以 (s, α, β) 为参数的回溯法, 均有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

其中

$$M = \begin{cases} h(1 - \frac{Lh}{2}), & \text{常数步长;} \\ \frac{1}{2L}, & \text{精确线搜索;} \\ \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\}, & \text{回溯法.} \end{cases}$$

情形 1: 常数步长 $h \in (0, \frac{2}{L})$ 充分下降引理的直接结论.

情形 1: 常数步长 $h \in (0, \frac{2}{L})$ 充分下降引理的直接结论.

情形 2: 精确线搜索 设 $\bar{h} = \arg \min_{h>0} f(\mathbf{x}_k - h \nabla f(\mathbf{x}_k))$, $\mathbf{x}_{k+1} = \mathbf{x}_k - \bar{h} \nabla f(\mathbf{x}_k)$.

由 $\bar{h}$ 的最优性, 有

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - \bar{h} \nabla f(\mathbf{x}_k)) \leq f(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k)),$$

情形 1: 常数步长 $h \in (0, \frac{2}{L})$ 充分下降引理的直接结论.

情形 2: 精确线搜索 设 $\bar{h} = \arg \min_{h>0} f(\mathbf{x}_k - h \nabla f(\mathbf{x}_k))$, $\mathbf{x}_{k+1} = \mathbf{x}_k - \bar{h} \nabla f(\mathbf{x}_k)$.

由 $\bar{h}$ 的最优性, 有

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k - \bar{h} \nabla f(\mathbf{x}_k)) \leq f(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k)),$$

故

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq f(\mathbf{x}_k) - f(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k)) \geq \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2.$$

情形 3: 回溯法 若 $s(1 - \frac{Ls}{2}) \geq \alpha s$, 由充分下降引理, 此时回溯法步长 $h_k = s$.

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha s \|\nabla f(\mathbf{x}_k)\|^2.$$

情形 3: 回溯法 若 $s(1 - \frac{Ls}{2}) \geq \alpha s$, 由充分下降引理, 此时回溯法步长 $h_k = s$.

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha s \|\nabla f(\mathbf{x}_k)\|^2.$$

否则, 由回溯法的执行过程知

$$\beta^{i_k-1} s (1 - \frac{L\beta^{i_k-1}s}{2}) \leq f(\mathbf{x}_k) - f(\mathbf{x}_k - \beta^{i_k-1}s \nabla f(\mathbf{x}_k)) < \alpha \beta^{i_k-1} \|\nabla f(\mathbf{x}_k)\|^2$$

解得 $\beta^{i_k} s > \frac{2(1-\alpha)\beta}{L}$,

情形 3: 回溯法 若 $s(1 - \frac{Ls}{2}) \geq \alpha s$, 由充分下降引理, 此时回溯法步长 $h_k = s$.

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha s \|\nabla f(\mathbf{x}_k)\|^2.$$

否则, 由回溯法的执行过程知

$$\beta^{i_k-1} s (1 - \frac{L\beta^{i_k-1}s}{2}) \leq f(\mathbf{x}_k) - f(\mathbf{x}_k - \beta^{i_k-1}s \nabla f(\mathbf{x}_k)) < \alpha \beta^{i_k-1} \|\nabla f(\mathbf{x}_k)\|^2$$

解得 $\beta^{i_k} s > \frac{2(1-\alpha)\beta}{L}$,

故 $h_k \geq \min\{s, \frac{2(1-\alpha)\beta}{L}\}$, 又因为回溯法步长满足

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq \alpha h_k \|\nabla f(\mathbf{x}_k)\|^2 \geq \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\} \|\nabla f(\mathbf{x}_k)\|^2.$$

L-smooth 函数收敛性

定理 3

设 f 为 L -smooth, $\{\mathbf{x}_k\}$ 为梯度下降法产生的迭代序列, $\mathbf{x}^*$ 为无约束优化问题的全局最优解, 则

$$\min_{k=0,\dots,K} \|\nabla f(\mathbf{x}_k)\| \leq \sqrt{\frac{f(\mathbf{x}_0) - f(\mathbf{x}^*)}{M(K+1)}},$$

其中

$$M = \begin{cases} h(1 - \frac{Lh}{2}), & \text{常数步长;} \\ \frac{1}{2L}, & \text{精确线搜索;} \\ \alpha \min\{s, \frac{2(1-\alpha)\beta}{L}\}, & \text{回溯法.} \end{cases}$$

证明

由引理 2.2 有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

记 $\Delta_k = f(\mathbf{x}_k) - f(\mathbf{x}^*)$, 则

$$M \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_k - \Delta_{k+1}, \quad k = 0, 1, \dots, K$$

证明

由引理 2.2 有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

记 $\Delta_k = f(\mathbf{x}_k) - f(\mathbf{x}^*)$, 则

$$M \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_k - \Delta_{k+1}, \quad k = 0, 1, \dots, K$$

对此 $K+1$ 项求和, 可得

$$(K+1)M \left(\min_{k=0, \dots, K} \|\nabla f(\mathbf{x}_k)\| \right)^2 \leq M \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_0 - \Delta_{K+1} \leq \Delta_0 = f(\mathbf{x}_0) - f(\mathbf{x}^*).$$

证明

由引理 2.2 有

$$f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq M \|\nabla f(\mathbf{x}_k)\|^2$$

记 $\Delta_k = f(\mathbf{x}_k) - f(\mathbf{x}^*)$, 则

$$M \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_k - \Delta_{k+1}, \quad k = 0, 1, \dots, K$$

对此 $K+1$ 项求和, 可得

$$(K+1)M \left(\min_{k=0, \dots, K} \|\nabla f(\mathbf{x}_k)\| \right)^2 \leq M \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 \leq \Delta_0 - \Delta_{K+1} \leq \Delta_0 = f(\mathbf{x}_0) - f(\mathbf{x}^*).$$

整理得到

$$\min_{k=0, \dots, K} \|\nabla f(\mathbf{x}_k)\| \leq \sqrt{\frac{f(\mathbf{x}_0) - f(\mathbf{x}^*)}{M(K+1)}}.$$

凸函数收敛性

假设目标函数 f 为可微凸函数, 则有

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle$$

凸函数收敛性

假设目标函数 f 为可微凸函数, 则有

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle$$

关于不等式右边内积项, 有

$$\begin{aligned} \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle &= \frac{1}{2h} \left(h^2 \|\nabla f(\mathbf{x}_k)\|^2 + \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_k - h\nabla f(\mathbf{x}_k) - \mathbf{x}^*\|^2 \right) \\ &= \frac{1}{2h} \left(h^2 \|\nabla f(\mathbf{x}_k)\|^2 + \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right) \end{aligned}$$

即

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \frac{1}{2h} \left(h^2 \|\nabla f(\mathbf{x}_k)\|^2 + \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

取 $k = 0, 1, \dots, K$, 求 $K + 1$ 项和.

$$\begin{aligned}\sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \left(\|\mathbf{x}_0 - \mathbf{x}^*\|^2 - \|\mathbf{x}_{K+1} - \mathbf{x}^*\|^2 \right) \\ &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \|\mathbf{x}_0 - \mathbf{x}^*\|^2\end{aligned}$$

取 $k = 0, 1, \dots, K$, 求 $K + 1$ 项和.

$$\begin{aligned}\sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \left(\|\mathbf{x}_0 - \mathbf{x}^*\|^2 - \|\mathbf{x}_{K+1} - \mathbf{x}^*\|^2 \right) \\ &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \|\mathbf{x}_0 - \mathbf{x}^*\|^2\end{aligned}$$

若有 $\|\nabla f(\mathbf{x}_k)\| \leq B$, $\|\mathbf{x}_0 - \mathbf{x}^*\| \leq R$.

取 $k = 0, 1, \dots, K$, 求 $K+1$ 项和.

$$\begin{aligned}\sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \left(\|\mathbf{x}_0 - \mathbf{x}^*\|^2 - \|\mathbf{x}_{K+1} - \mathbf{x}^*\|^2 \right) \\ &\leq \frac{h}{2} \sum_{k=0}^K \|\nabla f(\mathbf{x}_k)\|^2 + \frac{1}{2h} \|\mathbf{x}_0 - \mathbf{x}^*\|^2\end{aligned}$$

若有 $\|\nabla f(\mathbf{x}_k)\| \leq B$, $\|\mathbf{x}_0 - \mathbf{x}^*\| \leq R$.

$$\sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{h(K+1)B^2}{2} + \frac{R^2}{2h}$$

不等式两端同时除 $K+1$

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{hB^2}{2} + \frac{R^2}{2h(K+1)}$$

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{hB^2}{2} + \frac{R^2}{2h(K+1)}$$

不等式右端关于步长 h 最小化, 此时取 $h = \frac{R}{B\sqrt{K+1}}$,

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{K+1}}$$

综合上述讨论, 可得到以下定理.

定理 4

设目标函数 f 为可微凸函数且 $\|\nabla f(\mathbf{x})\| \leq B$, 记 $\mathbf{x}^*$ 为 f 的全局最小值点, 若梯度下降法初始点 $\mathbf{x}_0$ 满足 $\|\mathbf{x}_0 - \mathbf{x}^*\| \leq R$, 取步长

$$h = \frac{R}{B\sqrt{K+1}}, K \in \mathbb{N},$$

则有

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{K+1}}.$$

综合上述讨论, 可得到以下定理.

定理 4

设目标函数 f 为可微凸函数且 $\|\nabla f(\mathbf{x})\| \leq B$, 记 $\mathbf{x}^*$ 为 f 的全局最小值点, 若梯度下降法初始点 $\mathbf{x}_0$ 满足 $\|\mathbf{x}_0 - \mathbf{x}^*\| \leq R$, 取步长

$$h = \frac{R}{B\sqrt{K+1}}, K \in \mathbb{N},$$

则有

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{K+1}}.$$

上述定理表明若迭代次数 $K+1 \geq \frac{R^2 B^2}{\epsilon^2}$, 则迭代过程产生的平均误差

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \epsilon.$$

L-smooth 凸函数收敛性

定理 5

设目标函数 f 为 L -smooth 凸函数, 记 $\mathbf{x}^*$ 为 f 的全局最小值点, 梯度下降法取步长 $h = \frac{1}{L}$, 则有

$$f(\mathbf{x}_{K+1}) - f(\mathbf{x}^*) \leq \frac{L \|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2(K+1)}, \quad K \in \mathbb{N}.$$

证明

回忆关于凸函数有

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \frac{1}{2h} \left(h^2 \|\nabla f(\mathbf{x}_k)\|^2 + \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

其中 h 为步长.

证明

回忆关于凸函数有

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \frac{1}{2h} \left(h^2 \|\nabla f(\mathbf{x}_k)\|^2 + \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

其中 h 为步长.

取 $h = \frac{1}{L}$, 上式可以表示为

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

由充分下降引理

$$f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2$$

得到控制单步梯度的上界

$$\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$$

由充分下降引理

$$f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2$$

得到控制单步梯度的上界

$$\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$$

代入

$$f(\mathbf{x}_k) - f(\mathbf{x}^*) \leq \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

化简为

$$f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*) \leq \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

$$f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*) \leq \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

上述不等式取 $k = 0, 1, \dots, K$, 求 $K + 1$ 项和.

$$\begin{aligned} \sum_{k=0}^K (f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*)) &\leq \frac{L}{2} \left(\|\mathbf{x}_0 - \mathbf{x}^*\|^2 - \|\mathbf{x}_{K+1} - \mathbf{x}^*\|^2 \right) \\ &\leq \frac{L}{2} \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \end{aligned}$$

$$f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*) \leq \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right).$$

上述不等式取 $k = 0, 1, \dots, K$, 求 $K+1$ 项和.

$$\begin{aligned} \sum_{k=0}^K (f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*)) &\leq \frac{L}{2} \left(\|\mathbf{x}_0 - \mathbf{x}^*\|^2 - \|\mathbf{x}_{K+1} - \mathbf{x}^*\|^2 \right) \\ &\leq \frac{L}{2} \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \end{aligned}$$

由充分下降引理, 序列 $\{f(\mathbf{x}_k)\}$ 单调不增, 故

$$(K+1) \cdot (f(\mathbf{x}_{K+1}) - f(\mathbf{x}^*)) \leq \sum_{k=0}^K (f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*)) \leq \frac{L}{2} \|\mathbf{x}_0 - \mathbf{x}^*\|^2,$$

整理得到

$$f(\mathbf{x}_{K+1}) - f(\mathbf{x}^*) \leq \frac{L \|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2(K+1)}$$

L-smooth 及 μ -强凸函数的收敛性

定理 6

设目标函数 f 为 L -smooth 凸函数, 记 $\mathbf{x}^*$ 为 f 的全局最小值点, 梯度下降法取步长 $h = \frac{1}{L}$, 则有

$$\|\mathbf{x}_K - \mathbf{x}^*\|^2 \leq \exp(-K\mu/L) \|\mathbf{x}_0 - \mathbf{x}^*\|^2, \quad K \in \mathbb{N}_+$$

证明

由 μ 强凸函数的定义

$$\frac{\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle$$

同时

$$\langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle = \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right)$$

证明

由 μ 强凸函数的定义

$$\frac{\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle$$

同时

$$\langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle = \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L}{2} \left(\|\mathbf{x}_k - \mathbf{x}^*\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right)$$

结合上述两个不等式, 整理得到

$$\frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L - \mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

$$\frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L - \mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

由充分下降引理, 得到控制单步梯度的上界

$$\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$$

$$\frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

由充分下降引理, 得到控制单步梯度的上界

$$\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$$

故有

$$\begin{aligned} \frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 &\leq f(\mathbf{x}^*) - f(\mathbf{x}_{k+1}) + \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \\ &\leq \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \end{aligned}$$

整理得到

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq \left(1 - \frac{\mu}{L}\right) \|\mathbf{x}_k - \mathbf{x}^*\|^2.$$

$$\frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq f(\mathbf{x}^*) - f(\mathbf{x}_k) + \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

由充分下降引理, 得到控制单步梯度的上界

$$\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$$

故有

$$\begin{aligned} \frac{L}{2} \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 &\leq f(\mathbf{x}^*) - f(\mathbf{x}_{k+1}) + \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \\ &\leq \frac{L-\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2 \end{aligned}$$

整理得到

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \leq \left(1 - \frac{\mu}{L}\right) \|\mathbf{x}_k - \mathbf{x}^*\|^2.$$

由此不等式递推得到

$$\|\mathbf{x}_K - \mathbf{x}^*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \leq \exp(-K\mu/L) \|\mathbf{x}_0 - \mathbf{x}^*\|^2, \quad K \in \mathbb{N}_+$$

总结

- L -smooth 函数

$$\min_{k=0,\dots,K} \|\nabla f(\mathbf{x}_k)\| \leq \sqrt{\frac{f(\mathbf{x}_0) - f(\mathbf{x}^*)}{M(K+1)}},$$

$$K = \mathcal{O}\left(\frac{1}{\epsilon^2}\right)$$

- 凸函数

$$\frac{1}{K+1} \sum_{k=0}^K (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{K+1}}.$$

$$K = \mathcal{O}\left(\frac{1}{\epsilon^2}\right)$$

- L -smooth 凸函数

$$f(\mathbf{x}_{K+1}) - f(\mathbf{x}^*) \leq \frac{L \|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2(K+1)}, \quad K \in \mathbb{N}.$$

$$K = \mathcal{O}\left(\frac{1}{\epsilon}\right)$$

- L -smooth 且 μ 凸函数

$$\|\mathbf{x}_K - \mathbf{x}^*\|^2 \leq \exp(-K\mu/L) \|\mathbf{x}_0 - \mathbf{x}^*\|^2, \quad K \in \mathbb{N}_+$$

$$K = \mathcal{O}\left(\log \frac{1}{\epsilon}\right)$$

收敛阶与复杂度上界

- 称 $\mathcal{O}(\log \frac{1}{\epsilon})$ 为线性收敛阶, 固定每走某常数步, 误差精度提升 1 位有效数字.
- 称 $\mathcal{O}\left(\left(\frac{1}{\epsilon}\right)^r\right)$ 为次线性收敛阶, 为了使得误差精度提升 1 位有效数字, 所需的迭代次数与当前的迭代总次数同阶.

收敛阶与复杂度上界

- 称 $\mathcal{O}(\log \frac{1}{\epsilon})$ 为线性收敛阶, 固定每走某常数步, 误差精度提升 1 位有效数字.
- 称 $\mathcal{O}\left((\frac{1}{\epsilon})^r\right)$ 为次线性收敛阶, 为了使得误差精度提升 1 位有效数字, 所需的迭代次数与当前的迭代总次数同阶.
- 复杂度上界回答了迭代次数达到何值能够保证误差被 ϵ 控制 (充分性).
- 但没有回答误差被 ϵ 控制至少需要多少次迭代 (必要性).