

最优化方法 第十讲

Weiwen Wang(王伟文)

暨南大学

2026 年 4 月 22 日

目录

- 1 动机：投影梯度法回顾
- 2 Bregman 距离
 - Bregman 距离性质
- 3 镜像下降法 (Mirror Descent)
 - 迭代格式
 - 例子
 - 收敛性分析
 - 投影梯度法与镜像下降法对比
- 4 复合模型的镜像下降
 - 临近次梯度法
 - 收敛性分析

考虑优化问题

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) \\ \text{s.t. } \mathbf{x} \in C \end{aligned}$$

假设 1

- (1) f 是适定的闭凸函数;
- (2) C 为闭合凸集且 $C \subseteq \text{int}(\text{dom } f)$;
- (3) $X^* \triangleq \arg\min_{\mathbf{x} \in C} f(\mathbf{x})$ 非空, 记最优值为 f^* ;

投影梯度法

梯度投影法迭代格式

$$\begin{aligned}\mathbf{x}_{k+1} &= \Pi_C(\mathbf{x}_k - \gamma_k \mathbf{g}_k) \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k). \\ &= \arg \min_{\mathbf{x} \in C} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2\end{aligned}$$

投影梯度法

梯度投影法迭代格式

$$\begin{aligned}\mathbf{x}_{k+1} &= \Pi_C(\mathbf{x}_k - \gamma_k \mathbf{g}_k) \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k). \\ &= \arg \min_{\mathbf{x} \in C} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2 \\ &= \arg \min_{\mathbf{x} \in C} \frac{1}{2\gamma_k} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2\end{aligned}$$

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

投影梯度法

梯度投影法迭代格式

$$\begin{aligned}
 \mathbf{x}_{k+1} &= \Pi_C(\mathbf{x}_k - \gamma_k \mathbf{g}_k) \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k). \\
 &= \arg \min_{\mathbf{x} \in C} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2 \\
 &= \arg \min_{\mathbf{x} \in C} \frac{1}{2\gamma_k} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2 \\
 &= \arg \min_{\mathbf{x} \in C} \underbrace{f(\mathbf{x}_k) + \langle \mathbf{g}_k, \mathbf{x} - \mathbf{x}_k \rangle}_{f(\mathbf{x}) \text{ 线性化}} + \underbrace{\frac{1}{2\gamma_k} \|\mathbf{x} - \mathbf{x}_k\|_2^2}_{\text{距离的平方}} + \text{Const} \\
 &= \arg \min_{\mathbf{x} \in C} \left\{ \langle \mathbf{g}_k, \mathbf{x} \rangle + \frac{1}{2\gamma_k} \|\mathbf{x} - \mathbf{x}_k\|_2^2 \right\}
 \end{aligned}$$

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror
Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

投影梯度法一般化

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\mathbf{x} \in \mathbf{C}} \left\{ \langle \mathbf{g}_k, \mathbf{x} \rangle + \frac{1}{2\gamma_k} \operatorname{dist}_{\mathbf{C}}^2(\mathbf{x}, \mathbf{x}_k) \right\}.$$

Bregman 距离

定义 2

设 φ 为严格凸函数, $C \subseteq \text{dom}(\varphi)$, 且 φ 在闭凸集 C 上连续可微, 则 Bregman 距离定义为

$$B_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \quad \forall \mathbf{x}, \mathbf{y} \in C.$$

Bregman 距离不是严格意义上的距离

- $B_{\varphi}(\mathbf{x}, \mathbf{y}) = B_{\varphi}(\mathbf{y}, \mathbf{x})$ 不一定成立;
- 不满足三角不等式.

Bregman 距离

命题 3

设 φ 为 $\|\cdot\|$ 下的 μ -强凸函数, 则

- (a) $B_{\varphi}(\mathbf{x}, \mathbf{y}) \geq \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|^2;$
- (b) $B_{\varphi}(\mathbf{x}, \mathbf{y}) \geq 0;$
- (c) $B_{\varphi}(\mathbf{x}, \mathbf{y}) = 0$ iff. $\mathbf{x} = \mathbf{y}.$

证明.

a. 由强凸函数定义

$$\varphi(\mathbf{x}) \geq \varphi(\mathbf{y}) + \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|^2$$

故

$$\varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|^2$$

即 $B_{\varphi}(\mathbf{x}, \mathbf{y}) \geq \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|^2$.

b 和 **c** 的结论可立即有 **a** 得到. □

Bregman 距离

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

定理 4 (三点等式)

$\forall \mathbf{x}, \mathbf{y}, \mathbf{z} \in \text{dom } \varphi,$

$$B_{\varphi}(\mathbf{x}, \mathbf{z}) = B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z}) - \langle \nabla \varphi(\mathbf{z}) - \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

证明.

有 Bregman 定义

$$B_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

$$B_{\varphi}(\mathbf{y}, \mathbf{z}) = \varphi(\mathbf{y}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle$$

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

证明.

有 Bregman 定义

$$B_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

$$B_{\varphi}(\mathbf{y}, \mathbf{z}) = \varphi(\mathbf{y}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle$$

由 $B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z})$

$$\begin{aligned} B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z}) &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle \\ &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{x} - \mathbf{z} - (\mathbf{x} - \mathbf{y}) \rangle \end{aligned}$$

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

证明.

有 Bregman 定义

$$B_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

$$B_{\varphi}(\mathbf{y}, \mathbf{z}) = \varphi(\mathbf{y}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle$$

由 $B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z})$

$$\begin{aligned} B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z}) &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle \\ &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{x} - \mathbf{z} - (\mathbf{x} - \mathbf{y}) \rangle \\ &= B_{\varphi}(\mathbf{x}, \mathbf{z}) + \langle \nabla \varphi(\mathbf{z}) - \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \end{aligned}$$

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

证明.

有 Bregman 定义

$$B_{\varphi}(\mathbf{x}, \mathbf{y}) = \varphi(\mathbf{x}) - \varphi(\mathbf{y}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

$$B_{\varphi}(\mathbf{y}, \mathbf{z}) = \varphi(\mathbf{y}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle$$

由 $B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z})$

$$\begin{aligned} B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z}) &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle \\ &= \varphi(\mathbf{x}) - \varphi(\mathbf{z}) - \langle \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle - \langle \nabla \varphi(\mathbf{z}), \mathbf{x} - \mathbf{z} - (\mathbf{x} - \mathbf{y}) \rangle \\ &= B_{\varphi}(\mathbf{x}, \mathbf{z}) + \langle \nabla \varphi(\mathbf{z}) - \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \end{aligned}$$

移项得到

$$B_{\varphi}(\mathbf{x}, \mathbf{z}) = B_{\varphi}(\mathbf{x}, \mathbf{y}) + B_{\varphi}(\mathbf{y}, \mathbf{z}) - \langle \nabla \varphi(\mathbf{z}) - \nabla \varphi(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle$$

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

镜像下降法

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \mathbf{g}_k, \mathbf{x} \rangle + \frac{1}{2\gamma_k} \operatorname{dist}_{\mathcal{C}}^2(\mathbf{x}, \mathbf{x}_k) \right\}.$$

取 $\frac{1}{2} \operatorname{dist}_{\mathcal{C}}^2(\mathbf{x}, \mathbf{x}_k) \triangleq B_{\varphi}(\mathbf{x}, \mathbf{x}_k)$

镜像下降法

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \mathbf{g}_k, \mathbf{x} \rangle + \frac{1}{2\gamma_k} \operatorname{dist}_{\mathcal{C}}^2(\mathbf{x}, \mathbf{x}_k) \right\}.$$

取 $\frac{1}{2} \operatorname{dist}_{\mathcal{C}}^2(\mathbf{x}, \mathbf{x}_k) \triangleq B_{\varphi}(\mathbf{x}, \mathbf{x}_k)$

镜像下降法迭代格式

$$\begin{aligned} \mathbf{x}_{k+1} &= \operatorname{argmin}_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \mathbf{g}_k, \mathbf{x} \rangle + \frac{1}{\gamma_k} B_{\varphi}(\mathbf{x}, \mathbf{x}_k) \right\}. \\ &= \operatorname{argmin}_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \gamma_k \mathbf{g}_k, \mathbf{x} \rangle + B_{\varphi}(\mathbf{x}, \mathbf{x}_k) \right\} \\ &= \operatorname{argmin}_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \gamma_k \mathbf{g}_k - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \varphi(\mathbf{x}) \right\} \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k) \end{aligned}$$

镜像下降法

命题 5

若 φ 为 μ -强凸函数, 则镜像下降迭代格式

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\mathbf{x} \in \mathbf{C}} \{ \langle \gamma_k \mathbf{g}_k - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \varphi(\mathbf{x}) \} \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k)$$

是良态的, 即 $\mathbf{x}_{k+1}$ 存在且唯一.

例子

取所有范数为 ℓ_2 -范数, $\varphi(\mathbf{x}) = \frac{1}{2}\|\mathbf{x}\|_2^2$, $\varphi(\mathbf{x})$ 为 1-强凸函数,
 $\nabla\varphi(\mathbf{x}) = \mathbf{x}$.

$$\begin{aligned} B_{\varphi}(\mathbf{x}, \mathbf{y}) &= \frac{1}{2}\|\mathbf{x}\|_2^2 - \frac{1}{2}\|\mathbf{y}\|_2^2 - \langle \mathbf{y}, \mathbf{x} - \mathbf{y} \rangle \\ &= \frac{1}{2}\|\mathbf{x}\|_2^2 + \frac{1}{2}\|\mathbf{y}\|_2^2 - \langle \mathbf{x}, \mathbf{y} \rangle \\ &= \frac{1}{2}\|\mathbf{x} - \mathbf{y}\|_2^2 \end{aligned}$$

例子

取所有范数为 ℓ_2 -范数, $\varphi(\mathbf{x}) = \frac{1}{2}\|\mathbf{x}\|_2^2$, $\varphi(\mathbf{x})$ 为 1-强凸函数,
 $\nabla\varphi(\mathbf{x}) = \mathbf{x}$.

$$\begin{aligned} B_{\varphi}(\mathbf{x}, \mathbf{y}) &= \frac{1}{2}\|\mathbf{x}\|_2^2 - \frac{1}{2}\|\mathbf{y}\|_2^2 - \langle \mathbf{y}, \mathbf{x} - \mathbf{y} \rangle \\ &= \frac{1}{2}\|\mathbf{x}\|_2^2 + \frac{1}{2}\|\mathbf{y}\|_2^2 - \langle \mathbf{x}, \mathbf{y} \rangle \\ &= \frac{1}{2}\|\mathbf{x} - \mathbf{y}\|_2^2 \end{aligned}$$

此时镜像下降法迭代格式为

$$\begin{aligned} \mathbf{x}_{k+1} &= \arg\min_{\mathbf{x} \in \mathcal{C}} \left\{ \langle \gamma_k \mathbf{g}_k - \mathbf{x}_k, \mathbf{x} \rangle + \frac{1}{2}\|\mathbf{x}\|_2^2 \right\} \\ &= \arg\min_{\mathbf{x} \in \mathcal{C}} \left\{ \frac{1}{2}\|\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)\|_2^2 + \text{Const} \right\} \\ &= \Pi_{\mathcal{C}}(\mathbf{x} - (\mathbf{x}_k - \gamma_k \mathbf{g}_k)) \end{aligned}$$

例子

取所有范数为 ℓ_1 范数, $C \triangleq \Delta_d$, $\varphi(\mathbf{x}) = \sum_{i=1}^d x_i \ln x_i$, 取 $0 \cdot \ln 0 = 0$, $\varphi(\mathbf{x})$ 为 ℓ_1 范数下的 1-强凸函数. 定义

$$\Delta_d^+ = \left\{ \mathbf{x} \in \mathbb{R}^d : \sum_{i=1}^d x_i = 1, x_i > 0, i \in [d] \right\}$$

$$\nabla \varphi(\mathbf{y}) = (1 + \ln y_i)_{i \in [d]} \quad \forall \mathbf{y} \in \Delta_n^+$$

例子

取所有范数为 ℓ_1 范数, $C \triangleq \Delta_d$, $\varphi(\mathbf{x}) = \sum_{i=1}^d x_i \ln x_i$, 取 $0 \cdot \ln 0 = 0$, $\varphi(\mathbf{x})$ 为 ℓ_1 范数下的 1-强凸函数. 定义

$$\Delta_d^+ = \left\{ \mathbf{x} \in \mathbb{R}^d : \sum_{i=1}^d x_i = 1, x_i > 0, i \in [d] \right\}$$

$$\nabla \varphi(\mathbf{y}) = (1 + \ln y_i)_{i \in [d]} \quad \forall \mathbf{y} \in \Delta_n^+$$

$$\begin{aligned} B_\varphi(\mathbf{x}, \mathbf{y}) &= \sum_{i=1}^d x_i \ln x_i - \sum_{i=1}^d y_i \ln y_i - \sum_{i=1}^d (x_i - y_i)(1 + \ln y_i) \\ &= \sum_{i=1}^d x_i \ln \frac{x_i}{y_i} \quad \forall \mathbf{x} \in \Delta_d, \forall \mathbf{y} \in \Delta_d^+. \end{aligned}$$

例子

记 $\mathbf{y} = \mathbf{x}_k, \mathbf{g}_k \in \partial f(\mathbf{x}_k)$ 或 $\mathbf{g}_k = \nabla f(\mathbf{x}_k)$, $\mathbf{g} = \mathbf{g}_k$. 对应的镜像下降法为

$$\begin{aligned} \mathbf{x}_{k+1} &= \arg \min_{\mathbf{x} \in \Delta_d} \left\{ \sum_{i=1}^d \gamma_k g_i x_i + \sum_{i=1}^d x_i \ln \frac{x_i}{y_i} \right\} \\ &= \arg \min_{\mathbf{x} \in \Delta_d} \left\{ \sum_{i=1}^d \gamma_k g_i x_i + \sum_{i=1}^d x_i \ln x_i - \sum_{i=1}^d x_i \ln y_i \right\} \end{aligned}$$

例子

记 $\mathbf{y} = \mathbf{x}_k, \mathbf{g}_k \in \partial f(\mathbf{x}_k)$ 或 $\mathbf{g}_k = \nabla f(\mathbf{x}_k)$, $\mathbf{g} = \mathbf{g}_k$. 对应的镜像下降法为

$$\begin{aligned}\mathbf{x}_{k+1} &= \arg \min_{\mathbf{x} \in \Delta_d} \left\{ \sum_{i=1}^d \gamma_k g_i x_i + \sum_{i=1}^d x_i \ln \frac{x_i}{y_i} \right\} \\ &= \arg \min_{\mathbf{x} \in \Delta_d} \left\{ \sum_{i=1}^d \gamma_k g_i x_i + \sum_{i=1}^d x_i \ln x_i - \sum_{i=1}^d x_i \ln y_i \right\}\end{aligned}$$

解得

$$\mathbf{x}_{k+1,i} = \frac{\mathbf{x}_{k,i} e^{-\gamma_k \mathbf{g}_{k,i}}}{\sum_{j=1}^d \mathbf{x}_{k,j} e^{-\gamma_k \mathbf{g}_{k,j}}}.$$

收敛性分析

引理 6 (镜像下降基本不等式)

设 φ 为 $\|\cdot\|$ 下的 μ -强凸函数, $\mathbf{x}^*$ 为约束优化问题的最优解, 则镜像下降法的迭代序列 $\{\mathbf{x}_k\}$ 满足

$$\gamma_k(f(\mathbf{x}_k) - f^*) \leq B_\varphi(\mathbf{x}^*, \mathbf{x}_k) - B_\varphi(\mathbf{x}^*, \mathbf{x}_{k+1}) + \frac{\gamma_k^2}{2\mu} \|\mathbf{g}_k\|_*^2 \quad \forall k \geq 0,$$

其中 $\|\cdot\|_*$ 表示对偶范数.

证明.

由三点等式

$$B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) = B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) + B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \nabla \varphi(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle$$

同时由最优性条件

$$\langle \gamma_k \mathbf{g}_k - \nabla \varphi(\mathbf{x}_k) + \nabla \varphi(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \geq 0.$$

即

$$\langle \gamma_k \mathbf{g}_k, \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \geq \langle \varphi(\mathbf{x}_k) - \varphi(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle$$



证明.

因此

$$B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k \mathbf{g}_k, \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \leq B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1})$$

$$\text{又因为 } B_{\varphi}(\mathbf{x}_k, \mathbf{x}_{k+1}) \geq \frac{\mu}{2} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2$$

$$\begin{aligned} B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k \mathbf{g}_k, \mathbf{x}^* - \mathbf{x}_{k+1} \rangle &= B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k \mathbf{g}_k, \mathbf{x}_k - \mathbf{x}_{k+1} \rangle + \langle \gamma_k \mathbf{g}_k, \mathbf{x}_k - \mathbf{x}^* \rangle \\ &\geq \frac{\mu}{2} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \frac{\gamma^2}{2\mu} \|\mathbf{g}_k\|_*^2 - \frac{\mu}{2} + \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 + \dots \\ &\geq -\frac{\gamma^2}{2\mu} \|\mathbf{g}_k\|_*^2 + \gamma_k (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \end{aligned}$$

综上,

$$\gamma_k (f(\mathbf{x}_k) - f(\mathbf{x}^*)) \leq B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) + \frac{\gamma_k^2}{2\mu} \|\mathbf{g}_k\|_*^2$$

动机: 投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

收敛性分析

由镜像下降基本不等式可直接得到

定理 7

设 φ 为 $\|\cdot\|$ 下的 μ -强凸函数, $\mathbf{x}^*$ 为约束优化问题的最优解, 则镜像下降法的迭代序列 $\{\mathbf{x}_k\}$ 满足

$$\min_{k=0,1,\dots,K} f(\mathbf{x}_k) - f^* \leq \frac{B_\varphi(\mathbf{x}^*, \mathbf{x}_0) + \sum_{k=0}^K \frac{\gamma_k^2}{2\mu} \|\mathbf{g}_k\|_*^2}{\sum_{k=0}^K \gamma_k} \quad \forall K \geq 0.$$

收敛性分析

若 $D = \max_{\mathbf{x} \in \mathcal{C}} B_\varphi(\mathbf{x}, \mathbf{x}_0)$, $\forall \mathbf{g}_k$, $\|\mathbf{g}_k\|_* \leq L_f$, 取

$$\gamma_k = \frac{\sqrt{2D\mu}}{L_f\sqrt{K+1}}$$

有

$$\min_{k=0,1,\dots,K} f(\mathbf{x}_k) - f^* \leq \frac{\sqrt{2DL_f}}{\sqrt{\mu(K+1)}}.$$

投影梯度法与镜像下降法对比

考虑约束优化问题

$$\min_{\mathbf{x} \in \Delta_d} f(\mathbf{x})$$

其中 f 为适定闭凸函数, 且 $\Delta_d \subseteq \text{int}(\text{dom } f)$, 取初始点

$$\mathbf{x}_0 = \frac{1}{d} \mathbf{1} = (1/d, \dots, 1/d)$$

欧氏空间

取 $\|\cdot\| = \|\cdot\|_2$, 此时 $\|\cdot\|_* = \|\cdot\|_2$, 令 $\varphi(\mathbf{x}) = \frac{1}{2}\|\mathbf{x}\|_2^2$, φ 为 1-强凸函数, $B_\varphi(\mathbf{x}, \mathbf{y}) = \frac{1}{2}\|\mathbf{x} - \mathbf{y}\|_2^2$.

镜像下降法即投影梯度法, 迭代格式

$$\mathbf{x}_{k+1} = \Pi_{\Delta_d}(\mathbf{x}_k - \gamma_k \mathbf{g}_k) \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k).$$

$$D = \max_{\mathbf{x} \in \Delta_d} B_\varphi(\mathbf{x}, \mathbf{x}_0) = \max_{\mathbf{x} \in \Delta_d} \frac{1}{2} \|\mathbf{x} - \frac{1}{d} \mathbf{1}\|_2^2 = \frac{1}{2} \left(1 - \frac{1}{d}\right) \leq \frac{1}{2},$$

欧氏空间

取 $\|\cdot\| = \|\cdot\|_2$, 此时 $\|\cdot\|_* = \|\cdot\|_2$, 令 $\varphi(\mathbf{x}) = \frac{1}{2}\|\mathbf{x}\|_2^2$, φ 为 1-强凸函数, $B_\varphi(\mathbf{x}, \mathbf{y}) = \frac{1}{2}\|\mathbf{x} - \mathbf{y}\|_2^2$.

镜像下降法即投影梯度法, 迭代格式

$$\mathbf{x}_{k+1} = \Pi_{\Delta_d}(\mathbf{x}_k - \gamma_k \mathbf{g}_k) \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k) \text{ 或 } \mathbf{g}_k = \nabla f(\mathbf{x}_k).$$

$$D = \max_{\mathbf{x} \in \Delta_d} B_\varphi(\mathbf{x}, \mathbf{x}_0) = \max_{\mathbf{x} \in \Delta_d} \frac{1}{2} \|\mathbf{x} - \frac{1}{d} \mathbf{1}\|_2^2 = \frac{1}{2} \left(1 - \frac{1}{d}\right) \leq \frac{1}{2},$$

若

$$\|\mathbf{g}\|_2 \leq L_{f,2}, \forall \mathbf{x} \in \Delta_d, \forall \mathbf{g} \in \partial f(\mathbf{x})$$

$$\min_{k=0,1,\dots,K} f(\mathbf{x}_k) - f^* \leq \frac{L_{f,2}}{\sqrt{K+1}}.$$

非欧氏空间

取 $\|\cdot\| = \|\cdot\|_1$, $\|\cdot\|_* = \|\cdot\|_\infty$, $\varphi(\mathbf{x}) = \sum_{i=1}^d x_i \log x_i$, φ 为 $\|\cdot\|_1$ 下的 1-强凸函数. 镜像下降法迭代格式为

$$\mathbf{x}_{k+1,i} = \frac{\mathbf{x}_{k,i} e^{-\gamma_k \mathbf{g}_{k,i}}}{\sum_{j=1}^d \mathbf{x}_{k,j} e^{-\gamma_k \mathbf{g}_{k,j}}} \quad \mathbf{g}_k \in \partial f(\mathbf{x}_k), i \in [d].$$

$$D = \max_{\mathbf{x} \in \Delta_d} B_\varphi(\mathbf{x}, \mathbf{x}_0) = \max_{\mathbf{x} \in \Delta_d} \sum_{i=1}^d x_i \ln(d \cdot x_i) = \ln d$$

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

若

$$\|\mathbf{g}\|_{\infty} \leq L_{f,\infty}, \forall \mathbf{x} \in \Delta_d, \forall \mathbf{g} \in \partial f(\mathbf{x})$$

$$\min_{k=0,1,\dots,K} f(\mathbf{x}_k) - f^* \leq \frac{\sqrt{2 \log d} L_{f,\infty}}{\sqrt{K+1}}.$$

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

"Worst-Case" 收敛性对比

$$\text{记 } C_2^f = \frac{L_{f,2}}{\sqrt{K+1}}, C_\infty^f = \frac{\sqrt{2\log d} L_{f,\infty}}{\sqrt{K+1}},$$

$$\rho^f = \frac{C_\infty^f}{C_2^f} = \sqrt{2\log d} \frac{L_{f,\infty}}{L_{f,2}}$$

"Worst-Case" 收敛性对比

$$\text{记 } C_2^f = \frac{L_{f,2}}{\sqrt{K+1}}, C_\infty^f = \frac{\sqrt{2\log d} L_{f,\infty}}{\sqrt{K+1}},$$

$$\rho^f = \frac{C_\infty^f}{C_2^f} = \sqrt{2\log d} \frac{L_{f,\infty}}{L_{f,2}}$$

因为 $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{d}\|\mathbf{x}\|_\infty, \forall \mathbf{x} \in \mathbb{R}^d$, 故

$$\frac{1}{\sqrt{d}} \leq \frac{L_{f,\infty}}{L_{f,2}} \leq 1$$

"Worst-Case" 收敛性对比

$$\text{记 } C_2^f = \frac{L_{f,2}}{\sqrt{K+1}}, C_\infty^f = \frac{\sqrt{2\log d} L_{f,\infty}}{\sqrt{K+1}},$$

$$\rho^f = \frac{C_\infty^f}{C_2^f} = \sqrt{2\log d} \frac{L_{f,\infty}}{L_{f,2}}$$

因为 $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{d}\|\mathbf{x}\|_\infty, \forall \mathbf{x} \in \mathbb{R}^d$, 故

$$\frac{1}{\sqrt{d}} \leq \frac{L_{f,\infty}}{L_{f,2}} \leq 1$$

因此

$$\frac{\sqrt{2\log d}}{\sqrt{d}} \leq \rho^f \leq \sqrt{2\log d}.$$

$$\frac{\sqrt{2\log d}}{\sqrt{d}} \leq \rho^f \leq \sqrt{2\log d}.$$

这意味着存在最坏的情形, 镜像下降法比投影梯度法快 $\mathcal{O}(\sqrt{d/\ln d})$ 倍.

复合模型的镜像下降

考虑复合优化问题

$$\min_{\mathbf{x} \in \text{dom } h} F(\mathbf{x}) \triangleq f(\mathbf{x}) + h(\mathbf{x})$$

假设 8

- $f, h: \mathbb{E} \rightarrow (-\infty, +\infty]$ 为适定闭凸函数
- $\text{dom } h \subseteq \text{int}(\text{dom } f)$
- $\|\mathbf{g}\|_* \leq L_f, \forall \mathbf{x} \in \text{dom } h, \forall \mathbf{g} \in \partial f(\mathbf{x})$
- $X^* \triangleq \operatorname{argmin}_{\mathbf{x} \in \mathbb{C}} F(\mathbf{x})$ 非空, 记最优值为 F^*

为方便起见 f 和 h 的次微分简记为 f' 和 g' .

解法一：直接套用镜像下降法

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\operatorname{dom} h} \{ \langle \gamma_k(f'(\mathbf{x}_k) + h'(\mathbf{x}_k)) - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \varphi(\mathbf{x}) \}$$

为方便起见 f 和 h 的次微分简记为 f' 和 g' .

解法一：直接套用镜像下降法

$$\mathbf{x}_{k+1} = \arg \min_{\text{dom } h} \{ \langle \gamma_k(f'(\mathbf{x}_k) + h'(\mathbf{x}_k)) - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \varphi(\mathbf{x}) \}$$

- 收敛性依赖 $F(\mathbf{x}) = f(\mathbf{x}) + g(\mathbf{x})$ 的 Lipschitz 常数, 首先没有假设 $g(\mathbf{x})$ 是 Lipschitz 连续; 其次, 即使 $g(\mathbf{x})$ 是 Lipschitz 连续, 两个函数相加得到更大的 Lipschitz 常数, 弱化收敛性.

动机：投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

解法二 (Mirror-C):

$$\begin{aligned}\mathbf{x}_{k+1} &= \arg \min_{\text{dom } h} \left\{ \langle \gamma_k f'(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \gamma_k h(\mathbf{x}) + \varphi(\mathbf{x}) \right\} \\ &= \arg \min_{\text{dom } h} \left\{ \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x} \rangle + \gamma_k h(\mathbf{x}) + B_\varphi(\mathbf{x}, \mathbf{x}_k) \right\}\end{aligned}$$

取 $\varphi(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2$, $B_\varphi(\mathbf{x}, \mathbf{y}) = \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$

Mirror-C

$$\begin{aligned}
 \mathbf{x}_{k+1} &= \operatorname{argmin}_{\mathbf{x} \in \operatorname{dom} h} \left\{ \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x} \rangle + \gamma_k h(\mathbf{x}) + B_\varphi(\mathbf{x}, \mathbf{x}_k) \right\} \\
 &= \operatorname{argmin}_{\mathbf{x} \in \operatorname{dom} h} \left\{ \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x} \rangle + \gamma_k h(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - \mathbf{x}_k\|_2^2 \right\} \\
 &= \operatorname{argmin}_{\mathbf{x} \in \operatorname{dom} h} \left\{ \gamma_k h(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - (\mathbf{x}_k - \gamma_k f'(\mathbf{x}_k))\|_2^2 \right\} \\
 &\triangleq \underbrace{\operatorname{prox}_{\gamma_k h(\mathbf{x})}(\mathbf{x}_k - \gamma_k f'(\mathbf{x}_k))}_{\text{Proximal Operator}}
 \end{aligned}$$

定理 9

若假设 8 成立且 $h(\mathbf{x})$ 为非负函数, φ 为 $\|\cdot\|$ 下的 μ -强凸函数. 设 $\mathbf{x}^*$ 为复合优化问题的最优解, 步长 γ_k 单调非增, 则 *Mirror-C* 迭代序列 $\{\mathbf{x}_k\}_{k=0}^K$ 满足

$$\min_{k=0,1,\dots,K} F(\mathbf{x}_k) - F^* \leq \frac{\gamma_0 h(\mathbf{x}_0) + B_\varphi(\mathbf{x}^*, \mathbf{x}_0) + \frac{1}{2\mu} \sum_{k=0}^K \gamma_k^2 \|f'(\mathbf{x}_k)\|_*^2}{\sum_{k=0}^K \gamma_k}$$

证明.

由三点等式

$$B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) = B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) + B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \nabla \varphi(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle$$

又因为

$$\mathbf{x}_{k+1} = \operatorname{argmin}_{\mathbf{x} \in \operatorname{dom} h} \{ \langle \gamma_k f'(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_k), \mathbf{x} \rangle + \gamma_k h(\mathbf{x}) + \varphi(\mathbf{x}) \}$$

由最优性条件, 存在 $h'(\mathbf{x}_{k+1}) \in \partial h(\mathbf{x}_{k+1})$ 使得

$$\gamma_k f'(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_k) + \gamma_k h'(\mathbf{x}_{k+1}) + \nabla \varphi(\mathbf{x}_{k+1}) = 0$$

即

$$\nabla \varphi(\mathbf{x}_k) - \nabla \varphi(\mathbf{x}_{k+1}) = \gamma_k f'(\mathbf{x}_k) + \gamma_k h'(\mathbf{x}_{k+1})$$



动机: 投影梯度法回顾

Bregman 距离

Bregman 距离性质

镜像下降法 (Mirror Descent)

迭代格式

例子

收敛性分析

投影梯度法与镜像下降法对比

复合模型的镜像下降

临近次梯度法

收敛性分析

续.

故

$$\begin{aligned} B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) &= B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k f'(\mathbf{x}_k) + \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \\ &\geq \frac{\mu}{2} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x}^* - \mathbf{x}_k + \mathbf{x}_k - \mathbf{x}_{k+1} \rangle - \langle \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \end{aligned}$$

续.

故

$$\begin{aligned}
 B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) &= B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k f'(\mathbf{x}_k) + \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \\
 &\geq \frac{\mu}{2} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x}^* - \mathbf{x}_k + \mathbf{x}_k - \mathbf{x}_{k+1} \rangle - \langle \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \\
 &\geq \gamma_k (f(\mathbf{x}_k) - f(\mathbf{x}^*)) - \frac{\gamma_k^2}{2\mu} \|f'(\mathbf{x}_k)\|_*^2 + \gamma_k (h(\mathbf{x}_k) - h(\mathbf{x}^*)) - \gamma_k (h(\mathbf{x}_k) - h(\mathbf{x}_{k+1}))
 \end{aligned}$$

续.

故

$$\begin{aligned}
 B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) &= B_{\varphi}(\mathbf{x}_{k+1}, \mathbf{x}_k) - \langle \gamma_k f'(\mathbf{x}_k) + \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \\
 &\geq \frac{\mu}{2} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \langle \gamma_k f'(\mathbf{x}_k), \mathbf{x}^* - \mathbf{x}_k + \mathbf{x}_k - \mathbf{x}_{k+1} \rangle - \langle \gamma_k h'(\mathbf{x}_{k+1}), \mathbf{x}^* - \mathbf{x}_{k+1} \rangle \\
 &\geq \gamma_k (f(\mathbf{x}_k) - f(\mathbf{x}^*)) - \frac{\gamma_k^2}{2\mu} \|f'(\mathbf{x}_k)\|_*^2 + \gamma_k (h(\mathbf{x}_k) - h(\mathbf{x}^*)) - \gamma_k (h(\mathbf{x}_k) - h(\mathbf{x}_{k+1}))
 \end{aligned}$$

又因为 $\gamma_k \geq \gamma_{k+1}$, 移项并整理得到

$$\gamma_k (F(\mathbf{x}_k) - F(\mathbf{x}^*)) \leq B_{\varphi}(\mathbf{x}^*, \mathbf{x}_k) - B_{\varphi}(\mathbf{x}^*, \mathbf{x}_{k+1}) + \frac{\gamma_k^2}{2\mu} \|f'(\mathbf{x}_k)\|_*^2 + \gamma_k h(\mathbf{x}_k) - \gamma_{k+1} h(\mathbf{x}_{k+1})$$



稳健回归

考虑优化问题

$$\min_{\mathbf{x} \in \mathbb{R}^d} \left\{ F(\mathbf{x}) \triangleq \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_1 + \lambda \|\mathbf{x}\|_1 \right\}$$

- 投影次梯度法, $\gamma_k = \frac{1}{\|F'(\mathbf{x}_k)\|_2 \sqrt{k+1}}$ (解法一)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \left(\mathbf{A}^T \text{sgn}(\mathbf{A}\mathbf{x}_k - \mathbf{b}) + \lambda \text{sgn}(\mathbf{x}_k) \right)$$

- 临近次梯度法 (Mirror-C: $\varphi(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2$), $\gamma_k = \frac{1}{\|f'(\mathbf{x}_k)\|_2 \sqrt{k+1}}$ (解法二)

$$\mathbf{x}_{k+1} = \text{prox}_{\lambda \gamma_k \|\cdot\|_1} \left(\mathbf{x}_k - \gamma_k \left(\mathbf{A}^T \text{sgn}(\mathbf{A}\mathbf{x}_k - \mathbf{b}) \right) \right)$$