

最优化方法 第十讲

Weiwen Wang(王伟文)

暨南大学

2026 年 5 月 15 日

目录

1 有限和目标函数

2 方差缩减方法

- SGD_*
- SGD_* 的收敛性分析
- 随机平均梯度 (Stochastic Average Gradient, SAG)
- Stochastic Average Gradient Amélioré: SAGA
- 随机方差缩减梯度 (Stochastic Reduced Gradient, SVRG)
- SVRG 收敛性分析

有限和目标函数

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

考虑优化问题

$$\min_{\mathbf{x}} f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}),$$

其中 $f_i: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微.

- 梯度下降法 (Gradient Descent, GD)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x})$$

- 小批量梯度下降法 (Min-Batch, MBGD)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \frac{1}{|\mathcal{B}_k|} \sum_{i \in \mathcal{B}_k} \nabla f_i(\mathbf{x}) \quad \mathcal{B} \subseteq \{1, 2, \dots, n\}.$$

- 随机梯度下降法 (Stochastic Gradient Descent, SGD)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \nabla f_{i_k}(\mathbf{x}_k) \quad i_k \sim \text{Unif}(1, 2, \dots, n)$$

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

SGD 不收敛: $\lim_{k \rightarrow \infty} \nabla f(\mathbf{x}_k) \neq 0$

有限和目标函数

方差缩减方法

SGD*


SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)

Stochastic Average Gradient
Amélioré: SAGA

随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析



Gower, Robert M., et al. "Variance-reduced methods for machine learning."

Proceedings of the IEEE 108.11 (2020): 1968-1983.

引理 1

设 $X \in R^d$ 为随机向量存在有限方差, 则有

$$\mathbb{E} \left[\|X - \mathbb{E}[X]\|^2 \right] \leq \mathbb{E}[\|X\|^2]$$

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

证明.

$$\begin{aligned}\mathbb{E} \left[\|X - \mathbb{E}X\|^2 \right] &= \mathbb{E} \left[\|X\|^2 - 2\langle X, \mathbb{E}X \rangle + \|\mathbb{E}X\|^2 \right] \\ &= \mathbb{E}[\|X\|^2] - \|\mathbb{E}X\|^2 \leq \mathbb{E}[\|X\|^2].\end{aligned}$$



SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

引理 2

设 f 为 L -smooth 凸函数, 则有

$$f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{1}{2L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2 \leq f(\mathbf{y}).$$

定义 3 (方差缩减性质 (Variance Reduction Property, VRP))

设随机序列 $\{\mathbf{g}_k\}_{k \geq 0} \subset \mathbb{R}^d$, 若有

$$\mathbb{E} \left[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2 \right] \rightarrow 0 \quad \text{当} \quad k \rightarrow \infty$$

则称随机序列 $\{\mathbf{g}_k\}_{k \geq 0}$ 满足方差缩减性质.

方差缩减方法

SGD_{*}SGD_{*} 的收敛性分析随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

如何构造满足方差缩减性质的随机序列 $\{\mathbf{g}_k\}_{k \geq 0}$?

- $\nabla f(\mathbf{x}_k) \approx \mathbf{g}_k$
- $\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \mathbf{g}_k$

原型方法-SGD_{*}

假设已知 $\mathbf{x}^*$ 为有限和优化问题的最优解, 则定义

$$\mathbf{g}_k = \nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*) \quad i_k \sim \text{Unif}(1, 2, \dots, n).$$

有限和目标函数

方差缩减方法

SGD_{*}

SGD_{*} 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)

Stochastic Average Gradient
Amélioré: SAGA

随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

$\mathbf{g}_k$ 是 $\nabla f(\mathbf{x}_k)$ 的条件无偏估计.

$$\begin{aligned}\mathbb{E}[\mathbf{g}_k | \mathbf{x}_k] &= \mathbb{E}[\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*) | \mathbf{x}_k] \\ &= \sum_{i=1}^n \frac{1}{n} (f_i(\mathbf{x}_k) - f_i(\mathbf{x}^*)) \\ &= \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}_k) - \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}^*) \\ &= \nabla f(\mathbf{x}_k) - \nabla f(\mathbf{x}^*) = \nabla f(\mathbf{x}_k).\end{aligned}$$

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

$$\begin{aligned}\mathbb{E}\left[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2 | \mathbf{x}_k\right] &\stackrel{(i)}{\leq} \mathbb{E}\left[\|\mathbf{g}_k\|^2 | \mathbf{x}_k\right] \\ &\leq \mathbb{E}\left[\|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 | \mathbf{x}_k\right]\end{aligned}$$

故

$$\mathbb{E}\left[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2\right] \leq \mathbb{E}\left[\|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2\right]$$

若 $\mathbf{x}_k \rightarrow \mathbf{x}_*$, 则 $\{\mathbf{g}_k\}$ 满足 VRP.

引理 4

设 f_i 为 L_i -smooth 的凸函数, 记 $L_{\max} = \max_{i \in [n]} L_i$. 若 $i_k \sim \text{Unif}\{1, 2, \dots, n\}$, 则

$$\mathbb{E}_{i_k} \left[\|\nabla f_{i_k}(\mathbf{x}) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 \right] \leq 2L_{\max}(f(\mathbf{x}) - f(\mathbf{x}^*)) \quad \forall \mathbf{x} \in \mathbb{R}^d$$

证明.

由引理 2

$$\|\nabla f_{i_k}(\mathbf{x}) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 \leq 2L_{\max} \left(f_{i_k}(\mathbf{x}) - f_{i_k}(\mathbf{x}^*) - \langle \nabla f_{i_k}(\mathbf{x}^*), \mathbf{x} - \mathbf{x}^* \rangle \right) \quad \forall \mathbf{x} \in \mathbb{R}^d$$

不等式两侧同时关于 i_k 求期望

$$\begin{aligned} \mathbb{E}_{i_k} \|\nabla f_{i_k}(\mathbf{x}) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 &\leq \mathbb{E}_{i_k} \left[2L_{\max} \left(f_{i_k}(\mathbf{x}) - f_{i_k}(\mathbf{x}^*) - \langle \nabla f_{i_k}(\mathbf{x}^*), \mathbf{x} - \mathbf{x}^* \rangle \right) \right] \\ &= 2L_{\max} \left(\frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}) - \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}^*) - \left\langle \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}^*), \mathbf{x} - \mathbf{x}^* \right\rangle \right) \\ &= 2L_{\max}(f(\mathbf{x}_k) - f(\mathbf{x}^*)). \end{aligned}$$



定理 5

设 f_i 为 L_i -smooth 凸函数, f 为可微 μ -强凸函数, 记 $L_{\max} = \max_{i \in [n]} L_i$, 取步长 $\gamma \in (0, 1/L_{\max})$, SGD_* 迭代满足

$$\mathbb{E} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|\mathbf{x}_k - \mathbf{x}^*\|^2 \right] \quad \forall k \geq 0$$

和 VRP .

证明.

由迭代格式

$$\begin{aligned}
\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 &= \|\mathbf{x}_k - \gamma \mathbf{g}_k - \mathbf{x}^*\|^2 \\
&= \|\mathbf{x}_k - \mathbf{x}^*\|^2 - 2\langle \gamma \mathbf{g}_k, \mathbf{x}_k - \mathbf{x}^* \rangle + \gamma^2 \|\mathbf{g}_k\|^2 \\
&= \|\mathbf{x}_k - \mathbf{x}^*\|^2 - 2\gamma \langle \nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*), \mathbf{x}_k - \mathbf{x}^* \rangle + \gamma^2 \|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2
\end{aligned}$$

不等式两端在 $\mathbf{x}_k$ 条件下关于 i_k 求期望

$$\mathbb{E}_{i_k} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 | \mathbf{x}_k \right] = \|\mathbf{x}_k - \mathbf{x}^*\|^2 - 2\gamma \langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle + \gamma^2 \mathbb{E}_{i_k} \left[\|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 | \mathbf{x}_k \right]$$



证明.

 f 为 μ -强凸函数

$$\langle \nabla f(\mathbf{x}_k), \mathbf{x}_k - \mathbf{x}^* \rangle \geq f(\mathbf{x}_k) - f(\mathbf{x}^*) + \frac{\mu}{2} \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

由引理 4

$$\mathbb{E}_{i_k} \left[\|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 | \mathbf{x}_k \right] \leq 2L_{\max}(f(\mathbf{x}_k) - f(\mathbf{x}^*))$$

综合上述不等式

$$\mathbb{E}_{i_k} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 | \mathbf{x}_k \right] \leq \|\mathbf{x}_k - \mathbf{x}^*\|^2 - \gamma\mu\|\mathbf{x}_k - \mathbf{x}^*\|^2 - 2\gamma(1 - \gamma L_{\max})(f(\mathbf{x}_k) - f(\mathbf{x}^*))$$



证明.

注意到 $\gamma < 1/L_{\max}$ 且 $f(\mathbf{x}_k) - f(\mathbf{x}^*) \geq 0$. 故

$$\mathbb{E}_{\mathbf{x}_{k+1}} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 | \mathbf{x}_k \right] = \mathbb{E}_{i_k} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 | \mathbf{x}_k \right] \leq (1 - \mu\gamma) \|\mathbf{x}_k - \mathbf{x}^*\|^2$$

两端同时关于 $\mathbf{x}_k$ 求期望, 由塔公式法则

$$\mathbb{E} \left[\|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2 \right] \leq (1 - \mu\gamma) \mathbb{E} \left[\|\mathbf{x}_k - \mathbf{x}^*\|^2 \right]$$



SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

证明.

$$\begin{aligned}\mathbb{E} \left[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2 | \mathbf{x}_k \right] &\leq \mathbb{E} \left[\|\nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\mathbf{x}^*)\|^2 | \mathbf{x}_k \right] \\ &\leq \mathbb{E} \left[L_i^2 \|\mathbf{x}_k - \mathbf{x}^*\|^2 | \mathbf{x}_k \right] \\ &\leq L_{\max}^2 \|\mathbf{x}_k - \mathbf{x}^*\|^2\end{aligned}$$

故

$$\begin{aligned}\mathbb{E} \left[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2 \right] &\leq L_{\max}^2 \mathbb{E} \left[\|\mathbf{x}_k - \mathbf{x}^*\|^2 \right] \\ &\leq L_{\max}^2 (1 - \mu\gamma)^k \|\mathbf{x}_0 - \mathbf{x}^*\|^2\end{aligned}$$



定义辅助变量 $\mathbf{v}_k^{(i)}$

$$\mathbf{v}_k^{(j)} = \begin{cases} \nabla f_j(\mathbf{x}_k), & j = i_k \\ \mathbf{v}_{k-1}^{(j)}, & j \neq i_k \end{cases} \quad i_k \sim \text{Unif}(1, 2, \dots, n)$$

初始化为 $\mathbf{v}_0^{(i)} = \mathbf{0}, \forall i \in [n]$.

$$\begin{aligned} \mathbf{g}_k &= \frac{1}{n} \sum_{i=1}^n \mathbf{v}_k^{(i)} = \frac{1}{n} \sum_{j:j \neq i_k} \mathbf{v}_k^{(j)} + \frac{1}{n} \mathbf{v}_k^{(i_k)} = \frac{1}{n} \sum_{j:j \neq i_k} \mathbf{v}_{k-1}^{(j)} + \frac{1}{n} \mathbf{v}_k^{(i_k)} \\ &= \mathbf{g}_{k-1} - \frac{1}{n} \mathbf{v}_{k-1}^{(i_k)} + \frac{1}{n} \nabla f_{i_k}(\mathbf{x}_k) \end{aligned}$$

$\mathbf{g}_k$ 不是 $\nabla f(\mathbf{x}_k)$ 的一个无偏估计

$$\begin{aligned}\mathbb{E}[\mathbf{g}_k | \mathbf{x}_k] &= \mathbb{E} \left[\mathbf{g}_{k-1} - \frac{1}{n} \mathbf{v}_{k-1}^{(i_k)} + \frac{1}{n} \nabla f_{i_k}(\mathbf{x}_k) | \mathbf{x}_k \right] \\ &= \nabla f(\mathbf{x}_k) + \mathbf{g}_{k-1} - \frac{1}{n} \mathbf{g}_{k-1}\end{aligned}$$

给定一组向量 $\{\mathbf{v}_i\}_{i \in [n]}$,

$$\nabla f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \left(\nabla f_i(\mathbf{x}) - \mathbf{v}_i + \frac{1}{n} \sum_{i=1}^n \mathbf{v}_i \right)$$

记

$$\begin{aligned} \nabla f_i(\mathbf{x}; \mathbf{v}_i) &= \nabla f_i(\mathbf{x}) - \mathbf{v}_i + \frac{1}{n} \sum_{i=1}^n \mathbf{v}_i \\ &= \nabla f_i(\mathbf{x}) - \mathbf{v}_i + \mathbb{E}[\mathbf{v}_i] \end{aligned}$$

定义

$$\mathbf{g}_k = \nabla f_{i_k}(\mathbf{x}_k, \mathbf{v}_{i_k}) = \nabla f_{i_k}(\mathbf{x}) - \mathbf{v}_{i_k} + \mathbb{E}[\mathbf{v}_{i_k}] \quad i_k \sim \text{Unif}(1, 2, \dots, n)$$

方差缩减性质

$$\begin{aligned}\mathbb{E}_{i_k}[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2] &= \mathbb{E}_{i_k} \left[\|\nabla f_{i_k}(\mathbf{x}) - \mathbf{v}_{i_k} + \mathbb{E}[\mathbf{v}_{i_k}] - \nabla f(\mathbf{x}_k)\|^2 \right] \\ &\leq \mathbb{E}_{i_k} \left[\|\nabla f_{i_k}(\mathbf{x}_k) - \mathbf{v}_{i_k}\|^2 \right]\end{aligned}$$

若 $\nabla f_{i_k}(\mathbf{x}_k) \xrightarrow[k \rightarrow \infty]{} \mathbf{v}_{i_k}$, $\mathbb{E}_{i_k}[\|\mathbf{g}_k - \nabla f(\mathbf{x}_k)\|^2] \rightarrow 0$.

近似梯度

定义

$$\mathbf{v}_k^{(j)} = \nabla f_j(\mathbf{x}_{\setminus k})$$

其中 $\nabla f_j(\mathbf{x}_{\setminus k})$ 表示第 k 次迭代前最近一次计算的 f_j 的梯度。
迭代格式的近似梯度定义为

$$\mathbf{g}_k = \nabla f_{i_k}(\mathbf{x}_k) - \mathbf{v}_k^{(i_k)} + \frac{1}{n} \sum_{i=1}^n \mathbf{v}_k^{(i)} \quad i_k \sim \text{Unif}(1, 2, \dots, n)$$

高效计算

记 $\bar{\mathbf{g}}_{k-1} = \frac{1}{n} \sum_{i=1}^n \mathbf{v}_k^{(i)}$

- $i_k \in \text{Unif}(1, 2, \dots, n)$
- $\mathbf{g}_k = \nabla f_{i_k}(\mathbf{x}_k) - \mathbf{v}_k^{(i_k)} + \bar{\mathbf{g}}_{k-1}$
- $\mathbf{x}_{k+1} = \mathbf{x}_k - \gamma_k \mathbf{g}_k$
- $\bar{\mathbf{g}}_k = \bar{\mathbf{g}}_{k-1} - \frac{1}{n} \mathbf{v}_k^{(i_k)} + \frac{1}{n} \nabla f_{i_k}(\mathbf{x}_k)$

初始化取 $\mathbf{v}_0^{(i)} = \mathbf{0}, \forall i \in [n], \bar{\mathbf{g}}_0 = \mathbf{0}$.

SAG 和 SAGA 需要维持向量组 $\{\mathbf{v}_i\}$, 空间复杂度 $\mathcal{O}(nd)$.
SVRG 定义近似梯度

$$\mathbf{g}_k = \nabla f_{i_k}(\mathbf{x}_k) - \nabla f_{i_k}(\bar{\mathbf{x}}_k) + \nabla f(\bar{\mathbf{x}}_k)$$

空间复杂度 $\mathcal{O}(d)$.

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)Stochastic Average Gradient
Amélioré: SAGA随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

```
1 import numpy as np
2
3 def stochastic_variance_reduced_gradient(theta, step_size, sample_num,
4     outer_max, inner_max):
5     # compute full gradient of the finite sum objective function at theta
6     full_grad = gradient_of_obj(theta)
7     inner_theta = theta
8     for i in range(inner_max):
9         idx = np.random.randint(0, sample_num)
10        # compute individual gradient with index idx at inner_theta
11        grad1 = gradient_of_obj(inner_theta, idx)
12        # compute individual gradient with index idx at theta
13        grad2 = gradient_of_obj(theta, idx)
14        # gradient estimation
15        grad = grad1 - grad2 + full_grad
16        inner_theta += -step_size * grad
17
18    theta = inner_theta
19
20    return theta
```

定理 6

设 f_i 为 L_i -smooth 凸函数, f 为可微 μ -强凸函数, 记

$L_{\max} = \max_{i \in [n]} L_i$, 取步长 $\gamma \in (0, \frac{1}{2L_{\max}})$, 若 SVRG 内循环迭代次数 m 充分大使得

$$\rho \triangleq \frac{1}{\mu\gamma(1-2L_{\max}\gamma)m} + \frac{2L_{\max}\gamma}{1-2L_{\max}\gamma} < 1$$

则

$$\mathbb{E}[f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)] \leq \rho^s(f(\tilde{\mathbf{x}}_0) - f(\mathbf{x}^*)).$$

这里 $\tilde{\mathbf{x}}_s = \frac{1}{m} \sum_{i=0}^{m-1} \mathbf{x}_t$, 其中 $\mathbf{x}_t$ 表示第 s 次外循环中的第 t 次内循环更新结果, $\tilde{\mathbf{x}}_0$ 为初始点.

定理 6 的证明

记 $\tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$ 为第 $s-1$ 次外循环的迭代解, 在第 s 次外循环开始, 其对应的内循环初始化为 $\mathbf{x}_0 = \tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$.

定理 6 的证明

记 $\tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$ 为第 $s-1$ 次外循环的迭代解, 在第 s 次外循环开始, 其对应的内循环初始化为 $\mathbf{x}_0 = \tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$.

SVRG 的内循环更新公式为

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \eta \left(\nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right), \quad i_t \sim \text{Unif}[n].$$

其中 $t = 1, \dots, m$.

定理 6 的证明

记 $\tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$ 为第 $s-1$ 次外循环的迭代解, 在第 s 次外循环开始, 其对应的内循环初始化为 $\mathbf{x}_0 = \tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{s-1}$.

SVRG 的内循环更新公式为

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \eta \left(\nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right), \quad i_t \sim \text{Unif}[n].$$

其中 $t = 1, \dots, m$.

定义

$$\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}})$$

定理 6 的收敛性分析将从内循环出发.

定理 6 的证明

给定 $\tilde{\mathbf{x}}$ 和 $\mathbf{x}_{t-1}$,

$$\begin{aligned}\mathbb{E}\left[\|\mathbf{g}_t\|^2|\tilde{\mathbf{x}},\mathbf{x}_{t-1}\right] &= \mathbb{E}\left[\left\|\nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n}\sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}})\right\|^2|\tilde{\mathbf{x}},\mathbf{x}_{t-1}\right] \\ &= \mathbb{E}\left[\left\|\nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\mathbf{x}^*) + \left(\nabla f_{i_t}(\mathbf{x}^*) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n}\sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}})\right)\right\|^2|\tilde{\mathbf{x}},\mathbf{x}_{t-1}\right]\end{aligned}$$

定理 6 的证明

给定 $\tilde{\mathbf{x}}$ 和 $\mathbf{x}_{t-1}$,

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{g}_t\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] &= \mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&= \mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\mathbf{x}^*) + \left(\nabla f_{i_t}(\mathbf{x}^*) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\leq 2\mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\mathbf{x}^*) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}^*) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right]
\end{aligned}$$

定理 6 的证明

给定 $\tilde{\mathbf{x}}$ 和 $\mathbf{x}_{t-1}$,

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{g}_t\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] &= \mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&= \mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\mathbf{x}^*) + \left(\nabla f_{i_t}(\mathbf{x}^*) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\leq 2\mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}_{t-1}) - \nabla f_{i_t}(\mathbf{x}^*) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_t}(\mathbf{x}^*) - \nabla f_{i_t}(\tilde{\mathbf{x}}) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{\mathbf{x}}) \right\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\leq 4L_{\max} (f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*) + f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))
\end{aligned}$$

其中最后一个不等式由引理 4 得到.

定理 6 的证明

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{x}_t - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] &= \mathbb{E} \left[\|\mathbf{x}_{t-1} - \eta \mathbf{g}_t - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&= \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - 2\eta \langle \mathbb{E}[\mathbf{g}_t | \tilde{\mathbf{x}}, \mathbf{x}_{t-1}], \mathbf{x}_{t-1} - \mathbf{x}^* \rangle + \eta^2 \mathbb{E} \left[\|\mathbf{g}_t\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\leq \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - 2\eta \langle \mathbb{E}[\mathbf{g}_t | \tilde{\mathbf{x}}, \mathbf{x}_{t-1}], \mathbf{x}_{t-1} - \mathbf{x}^* \rangle \\
&\quad + 4L_{\max} \eta^2 (f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*) + f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))
\end{aligned}$$

定理 6 的证明

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{x}_t - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] &= \mathbb{E} \left[\|\mathbf{x}_{t-1} - \eta \mathbf{g}_t - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&= \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - 2\eta \langle \mathbb{E}[\mathbf{g}_t | \tilde{\mathbf{x}}, \mathbf{x}_{t-1}], \mathbf{x}_{t-1} - \mathbf{x}^* \rangle + \eta^2 \mathbb{E} \left[\|\mathbf{g}_t\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] \\
&\leq \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - 2\eta \langle \mathbb{E}[\mathbf{g}_t | \tilde{\mathbf{x}}, \mathbf{x}_{t-1}], \mathbf{x}_{t-1} - \mathbf{x}^* \rangle \\
&\quad + 4L_{\max} \eta^2 (f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*) + f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))
\end{aligned}$$

又因为 $\mathbb{E}[\mathbf{g}_t | \tilde{\mathbf{x}}, \mathbf{x}_{t-1}] = \nabla f(\mathbf{x}_{t-1})$, 且对任意给定 $\mathbf{x}_{t-1}$, 由强凸函数定义及 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 有

$$2\eta \langle \nabla f(\mathbf{x}_{t-1}), \mathbf{x}_{t-1} - \mathbf{x}^* \rangle \geq 2\eta (f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) + \eta \mu \|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2.$$

定理 6 的证明

整理得到

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{x}_t - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] &\leq \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - \eta \mu \|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 \\
&\quad - 2\eta(1 - 2L_{\max}\eta)(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) + 4L_{\max}\eta^2 (f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*)) \\
&\leq \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 | \tilde{\mathbf{x}}, \mathbf{x}_{t-1} \right] - 2\eta(1 - 2L_{\max}\eta)(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \\
&\quad + 4L_{\max}\eta^2 (f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))
\end{aligned}$$

左右两侧关于 $\tilde{\mathbf{x}}$ 和 $\mathbf{x}_{t-1}$ 求期望, 由塔式法则

$$\begin{aligned}
\mathbb{E} \left[\|\mathbf{x}_t - \mathbf{x}^*\|^2 \right] &\leq \mathbb{E} \left[\|\mathbf{x}_{t-1} - \mathbf{x}^*\|^2 \right] - 2\eta(1 - 2L_{\max}\eta)\mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \\
&\quad + 4L_{\max}\eta^2 \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*)),
\end{aligned}$$

其中 $t = 1, \dots, m$.

定理 6 的证明

注意到 $\mathbf{x}_0 = \tilde{\mathbf{x}}$, 将这 m 个不等式相加得到

$$\begin{aligned}\mathbb{E} \left[\|\mathbf{x}_m - \mathbf{x}^*\|^2 \right] &\leq \mathbb{E} \left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2 \right] - 2\eta(1 - 2L_{\max}\eta) \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \\ &\quad + 4L_{\max}\eta^2 m \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*)),\end{aligned}$$

有限和目标函数

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)

Stochastic Average Gradient
Amélioré: SAGA

随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

定理 6 的证明

注意到 $\mathbf{x}_0 = \tilde{\mathbf{x}}$, 将这 m 个不等式相加得到

$$\begin{aligned}\mathbb{E} \left[\|\mathbf{x}_m - \mathbf{x}^*\|^2 \right] &\leq \mathbb{E} \left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2 \right] - 2\eta(1 - 2L_{\max}\eta) \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \\ &\quad + 4L_{\max}\eta^2 m \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*)),\end{aligned}$$

移项得到

$$\mathbb{E} \left[\|\mathbf{x}_m - \mathbf{x}^*\|^2 \right] + 2\eta(1 - 2L_{\max}\eta) \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \leq \mathbb{E} \left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2 \right] + 4L_{\max}\eta^2 m \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

故

$$2\eta(1 - 2L_{\max}\eta) \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*)) \leq \mathbb{E} \left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2 \right] + 4L_{\max}\eta^2 m \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

定理 6 的证明

因为 $\tilde{\mathbf{x}}_s = \frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}$, 由 Jensen 不等式

$$f(\tilde{\mathbf{x}}_s) = f\left(\frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}\right) \leq \frac{1}{m} \sum_{t=0}^{m-1} f(\mathbf{x}_{t-1}),$$

故

$$m\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) \leq \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*))$$

有限和目标函数

方差缩减方法

SGD*

SGD* 的收敛性分析

随机平均梯度 (Stochastic
Average Gradient, SAG)

Stochastic Average Gradient
Amélioré: SAGA

随机方差缩减梯度 (Stochastic
Reduced Gradient, SVRG)

SVRG 收敛性分析

定理 6 的证明

因为 $\tilde{\mathbf{x}}_s = \frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}$, 由 Jensen 不等式

$$f(\tilde{\mathbf{x}}_s) = f\left(\frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}\right) \leq \frac{1}{m} \sum_{t=0}^{m-1} f(\mathbf{x}_{t-1}),$$

故

$$m\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) \leq \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*))$$

由强凸性质

$$\mathbb{E}\left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2\right] \leq \frac{2}{\mu} \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

定理 6 的证明

因为 $\tilde{\mathbf{x}}_s = \frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}$, 由 Jensen 不等式

$$f(\tilde{\mathbf{x}}_s) = f\left(\frac{1}{m} \sum_{t=0}^{m-1} \mathbf{x}_{t-1}\right) \leq \frac{1}{m} \sum_{t=0}^{m-1} f(\mathbf{x}_{t-1}),$$

故

$$m\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) \leq \sum_{t=1}^m \mathbb{E}(f(\mathbf{x}_{t-1}) - f(\mathbf{x}^*))$$

由强凸性质

$$\mathbb{E}\left[\|\tilde{\mathbf{x}} - \mathbf{x}^*\|^2\right] \leq \frac{2}{\mu} \mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

综合上述不等式,

$$2\eta(1 - 2L_{\max}\eta)m\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) \leq \left(\frac{2}{\mu} + 4L_{\max}\eta^2m\right)\mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

定理 6 的证明

综合上述不等式,

$$2\eta(1 - 2L_{\max}\eta)m\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) \leq \left(\frac{2}{\mu} + 4L_{\max}\eta^2m\right)\mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*))$$

因此

$$\begin{aligned}\mathbb{E}(f(\tilde{\mathbf{x}}_s) - f(\mathbf{x}^*)) &\leq \left(\frac{1}{\mu\eta(1 - 2L_{\max}\eta)m} + \frac{2L_{\max}\eta}{1 - 2L_{\max}\eta}\right)\mathbb{E}(f(\tilde{\mathbf{x}}) - f(\mathbf{x}^*)) \\ &= \left(\frac{1}{\mu\eta(1 - 2L_{\max}\eta)m} + \frac{2L_{\max}\eta}{1 - 2L_{\max}\eta}\right)\mathbb{E}(f(\tilde{\mathbf{x}}_{t-1}) - f(\mathbf{x}^*)).\end{aligned}$$

定理 6 的注释

- 若设 $\eta = \frac{c}{L_{\max}}$, 其中 $c > 0$ 为某一常数, 则

$$\begin{aligned}\frac{1}{\mu\eta(1-2L_{\max}\eta)m} + \frac{2L_{\max}\eta}{1-2L_{\max}\eta} &= \frac{L_{\max}}{\mu c(1-2c)m} + \frac{2c}{1-2c} \\ &= \mathcal{O}\left(\frac{L_{\max}}{\mu m} + \text{const}\right)\end{aligned}$$

定理 6 的注释

- 若设 $\eta = \frac{c}{L_{\max}}$, 其中 $c > 0$ 为某一常数, 则

$$\begin{aligned} \frac{1}{\mu\eta(1-2L_{\max}\eta)m} + \frac{2L_{\max}\eta}{1-2L_{\max}\eta} &= \frac{L_{\max}}{\mu c(1-2c)m} + \frac{2c}{1-2c} \\ &= \mathcal{O}\left(\frac{L_{\max}}{\mu m} + \text{const}\right) \end{aligned}$$

若设 $m = \mathcal{O}(L_{\max}/\mu)$, 则 ρ 为一常数, 此时 SVRG 的收敛率为 $\mathcal{O}(\log \frac{1}{\epsilon})$, 其总体算法复杂度为

$$\mathcal{O}\left((2m+n)\log \frac{1}{\epsilon}\right) = \mathcal{O}\left(\left(n + \frac{L_{\max}}{\mu}\right)\log \frac{1}{\epsilon}\right)$$

定理 6 的注释



$$\text{SVRG} : \mathcal{O} \left(\left(n + \frac{L_{\max}}{\mu} \right) \log \frac{1}{\epsilon} \right) \quad \text{vs} \quad \text{GD} : \mathcal{O} \left(n \frac{L}{\mu} \log \frac{1}{\epsilon} \right)$$